

FastAPI framework'ü yüksek performanslı asynchronous API desteği nedeniyle tercih edilmiştir.# CICIDS2017 Veri Seti Kullanılarak Random Forest, KNN ve SVM Algoritmaları ile Anomali Tabanlı Saldırı Tespit Sistemi Geliştirilmesi

Yasemin KIZILKAN TATAR
T.C. İstanbul Kültür Üniversitesi
Yüksek Bilgisayar Mühendisliği, Bilgisayar ve Ağ Güvenliği
İstanbul, Türkiye
2500002080@stu.iku.edu.tr, 2500002080

Abstract—Bu çalışmada, modern ağ ortamlarında gerçekleşen siber saldırıların tespit edilmesine yönelik makine öğrenmesi tabanlı bir Saldırı Tespit Sistemi (Intrusion Detection System - IDS) geliştirilmiştir. Çalışmada CICIDS2017 veri seti kullanılmış ve Random Forest, K-Nearest Neighbors (KNN) ve Support Vector Machine (SVM) algoritmaları karşılaştırmalı olarak değerlendirilmiştir. Geliştirilen sistem FastAPI tabanlı gerçek zamanlı bir servis mimarisi üzerine kurulmuş ve çoklu model yaklaşımı kullanılarak ensemble karar mekanizması geliştirilmiştir. Ayrıca modellerin karar süreçlerinin yorumlanabilmesi amacıyla feature importance ve permutation importance analizleri gerçekleştirilmiştir. Veri ön işleme sürecinde eksik veriler temizlenmiş, sonsuz değerler normalize edilmiş ve eğitim süresini optimize etmek amacıyla representative sampling yaklaşımı uygulanmıştır. Gerçek zamanlı analiz ekranı ile birlikte modellerin saldırı olasılık skorları, başarı metrikleri ve karar mekanizmaları görselleştirilmiştir. Deneysel sonuçlar Random Forest algoritmasının %99.78 doğruluk oranı ile en başarılı model olduğunu göstermiştir. KNN algoritması %99.61 doğruluk oranı ile yakın sonuçlar üretirken, SVM algoritması %91.89 doğruluk oranı elde etmiştir. Elde edilen sonuçlar, ensemble tabanlı çoklu model yaklaşımının ağ saldırılarının tespitinde etkili olduğunu göstermektedir.

Keywords— *Intrusion Detection System, Machine Learning, Random Forest, KNN, SVM, CICIDS2017, Cyber Security*

I. GİRİŞ

Dijitalleşmenin hız kazanması ile birlikte kurumların ağ altyapıları sürekli olarak daha karmaşık hale gelmektedir. Özellikle internet tabanlı servislerin artması, bulut teknolojilerinin yaygınlaşması ve uzaktan erişim ihtiyaçlarının büyümesi, siber saldırı yüzeyini önemli ölçüde genişletmiştir. Bu durum, geleneksel güvenlik yaklaşımlarının tek başına yeterli olmamasına neden olmuş ve akıllı saldırı tespit sistemlerine olan ihtiyacı artırmıştır. Saldırı Tespit Sistemleri (Intrusion Detection Systems - IDS), ağ trafiğini analiz ederek olağan dışı davranışları belirlemeyi amaçlayan güvenlik sistemleridir. IDS sistemleri temel olarak signature-based ve anomaly-based olmak üzere iki ana kategoriye ayrılmaktadır. Signature-based IDS sistemleri daha önce bilinen saldırı imzalarını kullanırken, anomaly-based IDS sistemleri normal ağ davranışlarını öğrenerek sapmaları tespit etmeye çalışmaktadır. Özellikle sıfırıncı gün saldırıları (Zero-Day Attacks) ve daha önce görülmemiş saldırı türleri karşısında anomaly-based sistemlerin daha başarılı sonuçlar verdiği görülmektedir. Makine öğrenmesi algoritmalarının gelişmesi ile birlikte anomaly-based IDS sistemleri akademik ve endüstriyel çalışmalarda önemli bir araştırma alanı haline gelmiştir [1]. Özellikle yüksek boyutlu ağ verilerinin işlenebilmesi, örüntülerin öğrenilebilmesi ve saldırı davranışlarının otomatik olarak sınıflandırılabilmesi, makine öğrenmesi yöntemlerini IDS sistemleri için güçlü adaylar haline getirmiştir. Bu çalışmada CICIDS2017 veri seti kullanılarak Random Forest, KNN ve SVM algoritmaları ile çoklu model tabanlı bir saldırı tespit sistemi geliştirilmiştir. Çalışmanın temel katkıları aşağıdaki gibidir: Random Forest, KNN ve SVM algoritmalarının aynı sistem üzerinde karşılaştırmalı olarak değerlendirilmesi. Ensemble karar mekanizması geliştirilmesi. Gerçek zamanlı FastAPI tabanlı IDS servis mimarisi oluşturulması. Feature importance ve permutation importance analizleri ile model açıklanabilirliğinin artırılması. Gerçek zamanlı demo paneli geliştirilmesi. Eğitim ve test veri setlerinin ayrıştırılarak gerçekçi değerlendirme yapılması. Bu yönüyle çalışma yalnızca teorik bir model eğitimi değil, aynı zamanda gerçek zamanlı çalışabilen bütünlük bir IDS prototipi sunmaktadır.

II. LİTERATÜR TARAMASI

Makine öğrenmesi tabanlı saldırı tespit sistemleri son yıllarda yoğun olarak çalışılan konular arasında yer almaktadır. Özellikle CICIDS2017 veri setinin yayınlanmasıyla birlikte, akademik çalışmalarda modern ağ saldırılarını temsil eden daha gerçekçi veri setleri kullanılmaya başlanmıştır.

Random Forest algoritması yüksek doğruluk oranları ve overfitting'e karşı dayanıklı yapısı nedeniyle IDS çalışmalarında yaygın olarak kullanılmaktadır [3]. Ensemble tabanlı yapısı sayesinde farklı karar ağaçlarının birleşiminden oluşan güçlü bir sınıflandırıcı yapısı sunmaktadır.

KNN algoritması ise örnek tabanlı öğrenme yaklaşımı ile özellikle düşük karmaşıklığa sahip veri kümelerinde başarılı sonuçlar üretebilmektedir [4]. Ancak büyük veri kümelerinde tahmin maliyetinin artması önemli dezavantajlarından biridir.

SVM algoritması özellikle yüksek boyutlu veri kümelerinde güçlü sınıflandırma yeteneği sunmaktadır [5]. Bununla birlikte büyük veri setlerinde eğitim maliyetinin yüksek olması sebebiyle genellikle optimize edilmiş veya lineer versiyonları tercih edilmektedir.

Client → Network Traffic → Feature Extraction → ML Models → IDS Decision

Şekil 1. IDS Sistemlerinin Genel Çalışma Yapısı

Şekil 1'de genel IDS mimarisi gösterilmektedir. Ağ trafiği istemciden alınmakta, feature extraction sürecinden geçirilmekte ve makine öğrenmesi modelleri tarafından analiz edilmektedir.

Tablo 1. Literatürdeki Benzer Çalışmalar

Çalışma	Veri Seti	Algoritmalar	Accuracy
Comparison of Random Forest, KNN and SVM for IDS	CICIDS2017	RF, KNN, SVM	%98 +
Benchmarking ML for IDS	CICIDS2017	RF, ANN, SVM	%99 +
Host Based IDS using RF and SVM	NSL-KDD	RF, SVM	%97 +

Literatürdeki çalışmalar incelendiğinde Random Forest algoritmasının çoğu zaman en yüksek başarıyı sağladığı görülmektedir. Bunun temel nedeni algoritmanın karmaşık veri dağılımlarını öğrenebilmesi ve feature importance analizi sağlayabilmesidir.

Bu çalışmada literatürdeki çalışmalardan farklı olarak yalnızca model başarısı değil, aynı zamanda gerçek zamanlı API servis mimarisi ve kullanıcı arayüzü de geliştirilmiştir.

III. VERİ SETİ VE VERİ ÖN İŞLEME

Bu çalışmada Canadian Institute for Cybersecurity tarafından yayınlanan CICIDS2017 veri seti kullanılmıştır. Veri seti modern ağ ortamlarını temsil edecek şekilde oluşturulmuş ve gerçek kullanıcı davranışları ile birlikte çeşitli saldırı türlerini içermektedir.

Veri setinde aşağıdaki saldırı türleri bulunmaktadır:

- DDoS
- DoS Hulk
- PortScan
- Botnet
- Web Attack
- Brute Force
- Infiltration

Veri seti toplamda onlarca feature içermektedir. Bu feature'lar ağ trafiğinin süre, paket sayısı, veri uzunluğu ve akış davranışları gibi bilgilerini temsil etmektedir.

Veri Seti İstatistikleri

Özellik	Değer
Kullanılan Veri Seti	CICIDS2017
Toplam Kullanılan Kayıt	100.000
Kullanılan Feature Sayısı	77
Train Veri Oranı	%80
Test Veri Oranı	%20
Kullanılan Algoritmalar	RF, KNN, SVM
Özellik	Değer
Problem Türü	Binary Classification

Çalışmada kullanılan veri seti hem normal ağ trafiğini hem de farklı saldırı türlerini içermektedir.

Representative sampling yaklaşımı ile eğitim süresi optimize edilirken veri çeşitliliğinin korunması amaçlanmıştır.

1) Veri Temizleme Süreci

Veri ön işleme sürecinde aşağıdaki işlemler uygulanmıştır:

1. Eksik verilerin temizlenmesi
2. Sonsuz değerlerin kaldırılması
3. Label normalizasyonu
4. Sayısal feature seçimi
5. Representative sampling uygulanması

Çalışmada eğitim süresini optimize etmek amacıyla representative sampling yaklaşımı uygulanmış ve

100.000 kayıtlık veri kümesi kullanılmıştır.

2) Eğitim/Test Ayrımı

Veri seti %80 eğitim ve %20 test olacak şekilde ayrılmıştır.

Bu çalışmada önemli olarak, demo panelinde kullanılan trafik örnekleri yalnızca test veri setinden seçilmiştir. Böylece modellerin eğitim sırasında görmediği örnekler üzerinde değerlendirme yapılmıştır.

Bu yaklaşım gerçek dünya senaryolarına daha yakın bir değerlendirme yapılmasını sağlamıştır.

IV. SİSTEM MİMARİSİ

1) Şekil 2. Geliştirilen IDS Sistem Mimarisi

Bu çalışmada geliştirilen sistem mimarisi aşağıdaki temel katmanlardan oluşmaktadır:

- FastAPI tabanlı servis katmanı
- Veri ön işleme katmanı
- Model değerlendirme katmanı
- Ensemble karar mekanizması
- Gerçek zamanlı kullanıcı arayüzü

Sistem mimarisi aşağıdaki akış üzerinden çalışmaktadır:

Client → FastAPI API → Feature Processing → RF / KNN / SVM → Ensemble Decision → Demo UI Geliştirilen sistem FastAPI tabanlı servis mimarisi üzerine kurulmuştur.

2) Şekil 1. Genel Sistem Akışı

Client → FastAPI → Feature Extraction
→ RF/KNN/SVM → Ensemble Decision
→ UI Panel Sistem mimarisi aşağıdaki

temel bileşenlerden oluşmaktadır:

- API Katmanı
- Model Katmanı
- Veri Ön İşleme Katmanı
- Ensemble Karar Mekanizması
- Demo Arayüzü

İstemci tarafından gönderilen ağ trafiği verisi öncelikle FastAPI servisi tarafından alınmaktadır. Daha sonra feature extraction sürecinden geçirilerek üç farklı makine öğrenmesi modeline gönderilmektedir.

Her model kendi saldırı olasılığını üretmekte ve sonuçlar ensemble karar mekanizması tarafından değerlendirilmektedir.

Nihai IDS kararı çoğunluk oylaması (Majority Voting) yaklaşımı ile belirlenmiştir.

Tek bir modele bağımlılığı azaltmak ve sistem güvenilirliğini artırmak amacıyla ensemble yaklaşımı tercih edilmiştir.

Ensemble karar mekanizması aşağıdaki şekilde modellenmiştir:

FinalDecision = MajorityVote(RF, KNN, SVM)

Bu yaklaşım sayesinde tek bir modele bağımlılık azaltılmış ve sistemin genel güvenilirliği artırılmıştır.

Bu çalışma yalnızca saldırı tespiti gerçekleştirmemekte, aynı zamanda modellerin karar süreçlerini açıklayabilmektedir. Bu yönüyle çalışma Explainable Artificial Intelligence (XAI) yaklaşımını desteklemektedir.

V. KULLANILAN ALGORİTMALAR

A. Random Forest

Random Forest algoritması çok sayıda karar ağacının birleşiminden oluşan ensemble tabanlı bir makine öğrenmesi algoritmasıdır [7].

Random Forest algoritmasının karar mekanizması aşağıdaki şekilde ifade edilmektedir: $H(x) = \arg\max_y \sum I(h_i(x)=y)$

Burada her karar ağacı kendi tahminini üretmekte ve nihai sonuç çoğunluk oylaması ile belirlenmektedir.

Her karar ağacı veri kümesinin farklı alt örnekleri üzerinde eğitilmektedir. Nihai karar çoğunluk oylaması ile belirlenmektedir.

Random Forest algoritmasının temel avantajları:

- Yüksek doğruluk oranı
- Overfitting'e karşı dayanıklılık
- Feature importance desteği
- Büyük veri kümelerinde başarılı performans

Bu çalışmada Random Forest algoritması en başarılı model olarak sonuç vermiştir.

B. K-Nearest Neighbors (KNN)

KNN algoritması örnek tabanlı öğrenme yaklaşımını kullanmaktadır [8].

KNN algoritmasında örnekler arasındaki uzaklık Öklid mesafesi kullanılarak hesaplanmaktadır: $d(x,y)=\sqrt{\sum (x_i - y_i)^2}$

Yeni gelen örnek, veri kümesindeki en yakın komşularına göre sınıflandırılmaktadır.

Bu çalışmada KNN için:

- n_neighbors = 11
- weights = distance parametreleri kullanılmıştır.

C. Support Vector Machine (SVM)

SVM algoritması verileri ayıran optimum hiper düzlemi bulmayı amaçlamaktadır [9]. SVM algoritmasının temel hiper düzlem denklemi aşağıdaki şekilde ifade edilmektedir: $f(x)=w^T x+b$ Bu çalışmada eğitim süresini optimize etmek amacıyla LinearSVC yaklaşımı tercih edilmiştir. Ayrıca olasılık skorlarının daha dengeli üretilebilmesi amacıyla CalibratedClassifierCV kullanılmıştır.

VI. MODEL EĞİTİMİ VE TEST SÜRECİ

1) Kullanılan Teknolojiler

Teknoloji	Kullanım Amacı
Python	Makine öğrenmesi geliştirme
FastAPI	REST API servis katmanı
Scikit-Learn	Makine öğrenmesi algoritmaları
Pandas	Veri işleme ve analiz
NumPy	Sayısal işlemler
Matplotlib	Grafik ve görselleştirme
Joblib	Model serileştirme

Geliştirilen sistem yalnızca model eğitimi amacıyla değil, gerçek zamanlı servis mimarisine uygun olacak şekilde tasarlanmıştır.

Modellerin eğitim sürecinde aşağıdaki adımlar uygulanmıştır:

2) Kullanılan Başarı Metrikleri

Accuracy metriği aşağıdaki şekilde hesaplanmaktadır: $Accuracy=(TP+TN)/(TP+TN+FP+FN)$

Precision metriği aşağıdaki şekilde hesaplanmaktadır: $Precision=TP/(TP+FP)$

Recall metriği aşağıdaki şekilde hesaplanmaktadır: $Recall=TP/(TP+FN)$

F1-Score metriği aşağıdaki şekilde hesaplanmaktadır: $F1=2 \times (Precision \times Recall) / (Precision + Recall)$

3) Model Eğitim Adımları

1. Veri temizleme
2. Feature seçimi
3. StandardScaler ile veri ölçekleme

KNN ve SVM algoritmalarının feature ölçeklerinden doğrudan etkilenmesi nedeniyle StandardScaler kullanılarak veri normalizasyonu gerçekleştirilmiştir.

Özellikle KNN algoritmasının distance-based yaklaşım kullanması sebebiyle feature ölçeklerinin dengelenmesi kritik önem taşımaktadır.

Benzer şekilde SVM algoritmasının hiper düzlem hesaplamalarında feature ölçeklerinden etkilenmesi nedeniyle ölçekleme işlemi model performansını doğrudan etkilemektedir. 4. Model eğitimi 5.

Probability calibration 6. Feature importance hesaplama 7. Test veri seti değerlendirmesi KNN ve SVM algoritmaları için permutation importance yöntemi kullanılmıştır.

Random Forest algoritması ise doğal feature importance desteği sunduğu için doğrudan feature importance analizi gerçekleştirilmiştir.

Ayrıca model olasılıklarının daha dengeli üretilebilmesi amacıyla CalibratedClassifierCV kullanılmıştır.

VII. DENEYSEL SONUÇLAR

Şekil 3. Veri Ön İşleme Süreci

Ham veri kümesi öncelikle temizleme ve normalizasyon süreçlerinden geçirilmiştir.

CICIDS2017 Dataset → Cleaning → Sampling → Scaling → Train/Test Split

Şekil 4. Model Eğitim Süreci


Model eğitim sürecinde üç farklı algoritma paralel olarak eğitilmiş ve sonuçları karşılaştırılmıştır.

Training Dataset → RF / KNN / SVM → Prediction → Ensemble Decision

Tablo 2. Model Başarı Karşılaştırması

Model	Accuracy	Precision	Recall	F1-Score
Random Forest	99.78	99.51	99.57	99.54
KNN	99.61	98.99	99.38	99.19
SVM	91.89	84.65	81.30	82.94


Şekil 5. Accuracy Karşılaştırma Grafiği



Şekil 5'te Random Forest, KNN ve SVM algoritmalarının doğruluk oranları karşılaştırılmıştır. Grafikte Random Forest algoritmasının %99.78 accuracy değeri ile en yüksek başarıyı sağladığı, KNN algoritmasının ise %99.61 accuracy değeri ile Random Forest'a oldukça yakın sonuç ürettiği görülmektedir. SVM algoritması %91.89 accuracy değeri ile diğer iki algoritmanın gerisinde kalmıştır.

Bu sonuçlar, CICIDS2017 veri seti üzerinde ensemble tabanlı ve örnek tabanlı yaklaşımların yüksek doğruluk sağlayabildiğini göstermektedir. Ancak genel başarı sıralaması Random Forest, KNN ve SVM şeklindedir.

Şekil 5A. Tüm Performans Metrikleri Karşılaştırması




Şekil 5A'da Accuracy, Precision, Recall ve F1-Score metrikleri birlikte karşılaştırılmıştır. Grafik incelendiğinde Random Forest ve KNN algoritmalarının tüm metriklerde birbirine yakın ve yüksek başarı ürettiği görülmektedir. Random Forest algoritması özellikle accuracy ve F1-score açısından en dengeli model olarak öne çıkmaktadır.

SVM algoritması ise özellikle recall ve F1-score değerlerinde belirgin şekilde daha düşük performans göstermiştir. Bu durum SVM'in saldırı örüntülerini yakalama kabiliyetinin Random Forest ve KNN'e kıyasla daha sınırlı kaldığını göstermektedir.

Şekil 5A. Modellerin Accuracy, Precision, Recall ve F1-Score metrikleri bakımından karşılaştırılması.


Şekil 6. Precision Karşılaştırma Grafiği



Şekil 6'da modellerin precision değerleri karşılaştırılmıştır. Random Forest algoritması %99.51 precision değeri ile en başarılı sonucu üretmiştir. KNN algoritması %98.99 precision değeri ile oldukça yakın bir performans göstermiştir. SVM algoritmasının precision değeri ise %84.65 olarak ölçülmüştür.

Precision metriği, modelin Attack olarak sınıflandırdığı örneklerin ne kadarının gerçekten Attack olduğunu göstermektedir. Bu nedenle Random Forest ve KNN algoritmalarının düşük yanlış alarm oranı ile çalıştığı söylenebilir.


Şekil 7. Recall Karşılaştırma Grafiği



Şekil 7’de modellerin recall değerleri karşılaştırılmıştır. Random Forest algoritması %99.57 recall değeri ile en yüksek saldırı yakalama başarısını elde etmiştir. KNN algoritması %99.38 recall değeri ile oldukça yakın sonuç üretmiştir. SVM algoritması ise %81.30 recall değeri ile saldırı örneklerini yakalama noktasında daha düşük performans göstermiştir.

Recall metriği, gerçek saldırı örneklerinin ne kadarının doğru şekilde Attack olarak sınıflandırıldığını göstermektedir. IDS sistemlerinde recall değerinin yüksek olması kritik öneme sahiptir; çünkü saldırı örneklerinin Normal olarak sınıflandırılması güvenlik riski doğurabilir.


Şekil 8. F1-Score Karşılaştırması



Şekil 8’de modellerin F1-score değerleri karşılaştırılmıştır. Random Forest algoritması %99.54 F1-score değeri ile en başarılı ve dengeli model olmuştur. KNN algoritması %99.19 F1-score değeri ile Random Forest’a yakın bir performans göstermiştir. SVM algoritması ise %82.94 F1-score değeri ile daha düşük genel sınıflandırma başarısı elde etmiştir.

F1-score metriği precision ve recall değerlerinin harmonik ortalaması olduğu için, modelin genel sınıflandırma başarısını daha dengeli şekilde yorumlamaya olanak tanır. Bu kapsamda Random Forest algoritmasının hem saldırı yakalama hem de yanlış alarmı azaltma açısından en başarılı model olduğu değerlendirilmiştir.


Şekil 9. Random Forest Feature Importance Analizi



Şekil 9’da Random Forest algoritmasına ait en etkili feature’lar gösterilmektedir. Grafiğe göre Bwd, Packet Length Std, Average Packet Size, Max Packet Length, Init_Win_bytes_forward, Init_Win_bytes_backward, Packet Length Variance ve Packet Length Mean değişkenleri model kararında yüksek katkıya sahiptir.

Bu sonuç, ağ paketlerinin boyut dağılımlarının ve akış davranışlarının saldırı tespitinde kritik rol oynadığını göstermektedir. Random Forest algoritmasının doğal feature importance desteği sayesinde modelin hangi trafik özelliklerinden daha fazla etkilendiği yorumlanabilir hale gelmiştir.


Şekil 10. KNN Feature Importance



Şekil 10’da KNN algoritması için permutation importance sonuçları gösterilmektedir. Grafiğe göre PSH, Flag Count, Down/Up Ratio , Init_Win_bytes_forward , Bwd Packets/s , ACK Flag Count , Flow Packets/s ve Packet Length Mean değişkenleri KNN modelinin karar sürecinde önemli rol oynamaktadır.

KNN distance-based çalışan bir algoritma olduğu için özellikle trafik oranları, bayrak sayıları ve paket akış hızları sınıflandırma sonucunu doğrudan etkileyebilmektedir.

Şekil 11 - SVM Feature Importance



Şekil 11’de SVM algoritmasına ait permutation importance sonuçları gösterilmektedir. Grafiğe göre Average Packet Size , Packet Length Variance , Flow IAT Std., Fwd IAT Max, Idle Max, Fwd IAT Std ve Bwd Packet Length Max değişkenleri SVM karar sürecinde öne çıkmaktadır.

SVM algoritmasında özellikle paket boyutu ve akış zamanlama özelliklerinin etkili olduğu görülmektedir. Bununla birlikte modelin lineer yaklaşım kullanması nedeniyle karmaşık saldırı örüntülerini Random Forest kadar başarılı şekilde ayıramadığı değerlendirilmiştir.

Feature Importance Analizi

Feature importance analizleri sonucunda özellikle aşağıdaki feature’ların saldırı tespitinde kritik olduğu görülmüştür:

- Flow Duration
- Packet Length Mean
- Total Fwd Packets
- Flow Bytes/s
- Bwd Packet Length Std

Bu feature’ların özellikle ağ trafiği davranışını temsil eden temel parametreler olduğu görülmektedir. Modellerin saldırı tespiti sırasında bu feature’lara daha yüksek ağırlık verdiği gözlemlenmiştir.

VIII. SONUÇLARIN YORUMLANMASI VE ALGORİTMA KARŞILAŞTIRMASI

Bu çalışmada Random Forest, KNN ve SVM algoritmaları aynı veri seti ve aynı ön işleme süreçleri kullanılarak karşılaştırılmıştır. Elde edilen sonuçlar doğruluk oranı, precision, recall ve F1-score metrikleri üzerinden değerlendirilmiştir.

A. Random Forest Algoritmasının Değerlendirilmesi

Random Forest algoritması %99.78 doğruluk oranı ile en başarılı model olmuştur.

Bu başarının temel nedeni algoritmanın ensemble tabanlı yapıya sahip olmasıdır. Çok sayıda karar ağacının birleşiminden oluşan yapı sayesinde karmaşık ağ trafik davranışları daha başarılı şekilde öğrenilebilmiştir.

Ayrıca Random Forest algoritması feature importance desteği sunduğu için saldırı tespitinde hangi feature’ların daha etkili olduğu analiz edilebilmiştir. Bu durum model açıklanabilirliği açısından önemli avantaj sağlamıştır.

Random Forest algoritmasının diğer önemli avantajları aşağıdaki gibidir:

- Overfitting’e karşı dayanıklı yapı
- Yüksek doğruluk oranı
- Büyük veri kümelerinde başarılı performans
- Feature importance desteği
- Ensemble karar mekanizması

Bu nedenlerle gerçek zamanlı saldırı tespit sistemleri için en uygun algoritmanın Random Forest olduğu değerlendirilmiştir.

B. KNN Algoritmasının Değerlendirilmesi

KNN algoritması %99.61 doğruluk oranı ile oldukça başarılı sonuçlar üretmiştir.

KNN algoritması örnek tabanlı öğrenme yaklaşımı kullandığı için özellikle benzer ağ trafik davranışlarını sınıflandırmada başarılı olmuştur.

Bununla birlikte algoritmanın prediction sürecinde tüm veri kümesi üzerinde nearest neighbor hesaplaması yapması işlem maliyetini artırmaktadır.

Özellikle yüksek boyutlu veri kümelerinde ve gerçek zamanlı sistemlerde prediction latency açısından dezavantaj oluşturabilmektedir.

Bu nedenle KNN algoritmasının yüksek doğruluk üretmesine rağmen production ortamlarında Random Forest kadar verimli olmayabileceği değerlendirilmiştir.

Özellikle prediction aşamasında tüm veri kümesi üzerinde nearest neighbor hesaplaması gerçekleştirmesi computational cost açısından dezavantaj oluşturmaktadır.

C. SVM Algoritmasının Değerlendirilmesi

SVM algoritması diğer modellere göre daha düşük başarı elde etmiştir.

Bunun temel nedeni CICIDS2017 veri setinin yüksek boyutlu ve karmaşık dağılıma sahip olmasıdır.

Bu çalışmada eğitim süresini optimize etmek amacıyla LinearSVC yaklaşımı tercih edilmiştir. Ancak lineer ayırma yaklaşımı karmaşık saldırı örüntülerini ayırmada sınırlı kalmıştır.

Bununla birlikte SVM algoritmasının daha düşük kaynak tüketimi ile çalışabilmesi önemli avantajlarından biridir.

Ayrıca CalibratedClassifierCV yaklaşımı sayesinde olasılık skorları daha dengeli hale getirilmiştir.

Computational Cost Karşılaştırması

Model	Eğitim Maliyeti	Prediction Maliyeti	Production Uygunluğu
Random Forest	Orta	Düşük	Yüksek
KNN	Düşük	Yüksek	Orta
SVM	Orta	Orta	Orta

Random Forest algoritmasının düşük prediction latency üretmesi gerçek zamanlı IDS sistemleri için önemli avantaj sağlamaktadır.

Threat Model Yaklaşımı

Bu çalışma aşağıdaki saldırı türlerini tespit etmeyi hedeflemektedir:

- DDoS
- DoS Hulk
- PortScan
- Brute Force
- Web Attack
- Botnet
- Infiltration

D. Nihai Algoritma Karşılaştırması

Kriter	Random Forest	KNN	SVM
Accuracy Başarısı	Yüksek	Yüksek	Orta
Gerçek Zamanlı Uygunluk	Yüksek	Orta	Orta
Açıklanabilirlik	Yüksek	Düşük	Orta
Prediction Hızı	Yüksek	Düşük	Orta
Production Uygunluğu	Yüksek	Orta	Orta
Feature Importance Desteği	Var	Permutation	Permutation

Elde edilen deneysel sonuçlar değerlendirildiğinde Random Forest algoritmasının hem doğruluk oranı hem de açıklanabilirlik açısından en başarılı yaklaşım olduğu görülmüştür.

Bu nedenle gerçek zamanlı saldırı tespit sistemleri için Random Forest tabanlı yaklaşımların daha uygun olduğu değerlendirilmiştir.

Ayrıca çoklu model yaklaşımının ensemble karar mekanizması ile birlikte kullanılması sistemin genel güvenilirliğini artırmıştır.

IX. DEMO PANELİ VE GERÇEK ZAMANLI ANALİZ

Şekil 12. ROC Curve Karşılaştırması

roc_curve_comparison.png grafiğinde modellerin ROC eğrileri karşılaştırılmıştır.

ROC eğrileri değerlendirildiğinde Random Forest ve KNN algoritmalarının daha başarılı ayırım yeteneğine sahip olduğu gözlemlenmiştir.

AUC değerlerinin 1'e oldukça yakın olması modellerin saldırı ve normal trafik ayırımını yüksek başarıyla gerçekleştirdiğini göstermektedir.


Özellikle AUC değerlerinin yüksek olması modellerin saldırı ve normal trafik ayırımını başarılı şekilde gerçekleştirebildiğini göstermektedir.

Şekil 13. Precision-Recall Curve Karşılaştırması

precision_recall_curve_comparison.png grafiğinde precision ve recall ilişkisi analiz edilmiştir.

Precision-Recall eğrileri değerlendirildiğinde Random Forest algoritmasının dengeli performans sergilediği görülmektedir.


Şekil 14. Random Forest Confusion Matrix



Şekil 14'te Random Forest algoritmasına ait confusion matrix gösterilmektedir. Test sonuçlarına göre model 15125 normal trafiği doğru şekilde Normal, 4830 saldırı trafiğini doğru şekilde Attack olarak sınıflandırmıştır. Buna karşılık yalnızca 24 normal trafik örneği Attack olarak, 21 saldırı trafik örneği ise Normal olarak sınıflandırılmıştır.

Bu sonuçlar Random Forest algoritmasının hem False Positive hem de False Negative oranlarının oldukça düşük olduğunu göstermektedir. IDS sistemleri açısından bu durum önemlidir; çünkü model hem saldırıları yüksek başarıyla yakalamakta hem de normal trafiği gereksiz yere saldırı olarak işaretleme oranını düşük tutmaktadır.


Şekil 15. KNN Confusion Matrix



Şekil 15'te KNN algoritmasına ait confusion matrix gösterilmektedir. KNN modeli 15100 normal örneği doğru şekilde Normal, 4821 saldırı örneğini doğru şekilde Attack olarak sınıflandırmıştır. Model 49 normal örneği Attack olarak, 30 saldırı örneğini ise Normal olarak sınıflandırmıştır.

Bu sonuçlar KNN algoritmasının genel olarak yüksek başarı gösterdiğini ancak Random Forest'a göre daha fazla yanlış sınıflandırma yaptığını göstermektedir. Özellikle benzer feature dağılımına sahip trafik örneklerinde nearest neighbor yaklaşımının bazı hatalı kararlar üretebildiği değerlendirilmektedir.

Şekil 16. SVM Confusion Matrix



Şekil 16'da SVM algoritmasına ait confusion matrix gösterilmektedir. SVM modeli 14434 normal örneği doğru

şekilde Normal, 3944 saldırı örneğini doğru şekilde Attack olarak sınıflandırmıştır. Ancak 715 normal trafik örneğini Attack olarak, 907 saldırı örneğini ise Normal olarak sınıflandırmıştır.

Bu sonuçlar SVM algoritmasının Random Forest ve KNN'e kıyasla daha yüksek False Positive ve False Negative oranlarına sahip olduğunu göstermektedir. Özellikle 907 saldırı örneğinin Normal olarak sınıflandırılması IDS sistemleri açısından kritik bir dezavantajdır. Bu durum SVM'in lineer ayırım yaklaşımının CICIDS2017 veri setindeki karmaşık saldırı örüntülerini ayırmada sınırlı kaldığını desteklemektedir.

IDS Demo Paneli:

Geliştirilen demo paneli gerçek zamanlı trafik analizi gerçekleştirebilmektedir. Panel üzerinde:

- Nihai IDS kararı
 - Algoritma bazlı attack olasılıkları
 - Accuracy metrikleri
 - Feature contribution sonuçları
 - Ensemble voting mekanizması
- Gösterilmektedir.

Sistem üç farklı modelin kararlarını birleştirerek nihai IDS sonucunu üretmektedir.

Random Forest + KNN + SVM → Majority Voting → Final IDS Decision

İstatistiksel Değerlendirme

Çalışma kapsamında elde edilen sonuçlar istatistiksel olarak değerlendirildiğinde Random Forest algoritmasının hem doğruluk hem de kararlılık açısından daha başarılı olduğu görülmektedir.

Özellikle precision ve recall sonuçlarının birlikte yüksek olması, modelin hem saldırıları başarılı şekilde yakalayabildiğini hem de yanlış alarm oranının düşük olduğunu göstermektedir.

KNN algoritması yüksek doğruluk üretmesine rağmen gerçek zamanlı prediction maliyetleri açısından dezavantaj oluşturabilmektedir.

SVM algoritması ise daha düşük başarı oranına sahip olmasına rağmen daha düşük kaynak tüketimi avantajı sağlamaktadır.

Bu sonuçlar değerlendirildiğinde gerçek zamanlı production ortamlarında Random Forest tabanlı IDS yaklaşımlarının daha uygun olduğu sonucuna ulaşılmıştır.

Çalışma kapsamında yalnızca model eğitimi değil, aynı zamanda gerçek zamanlı çalışan bir IDS demo paneli de geliştirilmiştir.

Geliştirilen panel:

- Yeni trafik örnekleri oluşturabilmekte
- Modellerin saldırı olasılıklarını gösterebilmekte
- Ensemble karar mekanizmasını görselleştirebilmekte
- Feature contribution sonuçlarını sunabilmektedir

Bu yönüyle çalışma akademik model eğitimini gerçek zamanlı servis mimarisi ile birleştirmektedir.

X. ÇALIŞMANIN KISITLARI

Bu çalışmada geliştirilen sistem başarılı sonuçlar üretmiş olmasına rağmen bazı kısıtlara sahiptir. Çalışmanın temel kısıtları aşağıdaki gibidir:

- Gerçek zamanlı canlı ağ trafiği yerine offline veri seti kullanılmıştır.
- Çalışmada yalnızca CICIDS2017 veri seti kullanılmıştır.
- Deep Learning tabanlı modeller değerlendirilmemiştir.
- Gerçek paket yakalama sistemleri ile entegrasyon gerçekleştirilmemiştir.
- Streaming veri analizi yapılmamıştır.

Bu kısıtlara rağmen çalışma gerçek zamanlı servis mimarisi ile çalışan başarılı bir IDS prototipi ortaya koymuştur.

XI. SONUÇ VE GELECEK ÇALIŞMALAR

Bu çalışmada CICIDS2017 veri seti kullanılarak makine öğrenmesi tabanlı çoklu algoritmali bir saldırı tespit sistemi geliştirilmiştir.

Random Forest, KNN ve SVM algoritmaları karşılaştırmalı olarak değerlendirilmiş ve Random Forest algoritmasının en başarılı sonuçları verdiği görülmüştür.

Ayrıca geliştirilen FastAPI tabanlı servis mimarisi sayesinde sistem gerçek zamanlı olarak çalıştırılabilir hale getirilmiştir.

Feature importance analizleri ile modellerin karar mekanizmaları yorumlanabilir hale getirilmiştir.

Gelecek çalışmalarda aşağıdaki geliştirmeler yapılabilir:

- Deep Learning tabanlı IDS modelleri
- Gerçek zamanlı ağ trafiği entegrasyonu
- Streaming veri analizi
- SIEM entegrasyonları
- Gerçek paket yakalama sistemleri
- Docker/Kubernetes tabanlı dağıtık mimariler

- Kafka tabanlı streaming mimarileri
- Wireshark entegrasyonu
- Gerçek paket yakalama sistemleri
- Deep Learning tabanlı IDS modelleri
- Federated Learning yaklaşımları
- SIEM sistem entegrasyonları
- Gerçek zamanlı log analizi
gibi geliştirmeler yapılabilir.

KAYNAKÇA

- [1] A. L. Buczak and E. Guven, "A Survey of Data Mining and Machine Learning Methods for Cyber Security Intrusion Detection," IEEE Communications Surveys & Tutorials, vol. 18, no. 2, pp. 1153–1176, 2016.
- [2] I. Sharafaldin, A. Habibi Lashkari and A. A. Ghorbani, "Toward Generating a New Intrusion Detection Dataset and Intrusion Traffic Characterization," ICISPP, 2018.
- [3] "Comparison of Random Forest, K-Nearest Neighbor, and Support Vector Machine Classifiers for Intrusion Detection System," IEEE Access.
- [4] T. Cover and P. Hart, "Nearest Neighbor Pattern Classification," IEEE Transactions on Information Theory, vol. 13, no. 1, pp. 21–27, 1967.
- [5] C. Cortes and V. Vapnik, "Support-Vector Networks," Machine Learning, vol. 20, pp. 273–297, 1995.
- [6] Canadian Institute for Cybersecurity, "CICIDS2017 Dataset," University of New Brunswick.
- [7] L. Breiman, "Random Forests," Machine Learning, vol. 45, no. 1, pp. 5–32, 2001.
- [8] E. Fix and J. Hodges, "Discriminatory Analysis, Nonparametric Discrimination," USAF School of Aviation Medicine, 1951.
- [9] B. Scholkopf and A. Smola, Learning with Kernels, MIT Press, 2002.